

Guion de la presentacion en video

Examen ML1 - Prediccion del precio de diamantes • Michele Castro Osorio • Machine Learning I • Prof. Danilo Alberto Gomez

Version corta (~6 min, deja margen bajo el limite de 8). Lee con calma, mira la pantalla y haz scroll por el notebook mientras hablas. No necesitas leer palabra por palabra: di las ideas con tus propias palabras.

Bloque 1 - Dataset y justificacion (0:00 - 1:00)

En pantalla: En pantalla: portada y tabla de declaracion del dataset.

"Hola profesor Gomez, soy Michele Castro Osorio y este es mi examen de Machine Learning I. El objetivo es predecir el precio de un diamante en dolares a partir de sus caracteristicas fisicas y de calidad. Elegi el dataset Diamonds de Kaggle: 53.940 observaciones y 9 variables predictoras. Cumple todos los requisitos: mas de 500 filas, seis variables numericas continuas -quilates, profundidad, tabla y las tres dimensiones x, y, z- y tres categoricas: corte, color y claridad. La variable objetivo es el precio, asi que es un problema de regresion. No esta en la lista de datasets prohibidos, y es un caso de negocio concreto: tasar diamantes."

Bloque 2 - EDA (1:00 - 3:00)

En pantalla: En pantalla: pasos 5 a 9 (nulos, outliers, distribucion del objetivo, correlaciones).

"En el analisis exploratorio hice primero un control de calidad. El dataset no tenia nulos explicitos, pero encontré unos 20 diamantes con dimensiones igual a cero, algo fisicamente imposible. Los marque como faltantes y los impute con la mediana dentro del pipeline. Con el metodo IQR revise los outliers: decidi mantener los diamantes grandes reales -porque son la parte cara del mercado- y corregir solo los errores groseros de captura. El precio esta muy sesgado a la derecha, con un skewness de 1,62; como supera 1, aplique una transformacion logaritmica y entreno los modelos sobre el precio en escala log. Las variables mas correlacionadas con el precio son el quilataje, con 0,92, y las tres dimensiones, alrededor de 0,88. Tambien detecte fuerte multicolinealidad entre ellas, con correlaciones sobre 0,97, porque todas miden esencialmente lo mismo: el tamano."

Bloque 3 - PCA + K-Means (3:00 - 4:00)

En pantalla: En pantalla: scree plot, tabla PCA, elbow/silhouette y perfil de clusters.

"Para el preprocesamiento, dividi en train y test antes de transformar, y ajuste el ColumnTransformer solo con los datos de entrenamiento, para no filtrar informacion del test. Con PCA, 4 componentes capturan el 86% de la varianza; el primer componente es un eje puro de tamano y el segundo, de geometria del tallado. Con K-Means, el Silhouette Score fue maximo en K igual a 2. Esos dos clusters tienen una lectura de negocio clarisima: uno agrupa diamantes premium y grandes, con precio medio de unos 7.000 dolares, y el otro, diamantes pequenos de entrada, con precio medio de unos 1.300. El modelo separo el mercado por tamano sin ver el precio."

Bloque 4 - Modelos y tabla comparativa (4:00 - 6:00)

En pantalla: En pantalla: celdas de entrenamiento, best_params_, tabla comparativa y grafico reales vs. predichos.

"Entrene tres modelos con semilla 42 y validacion cruzada de 5 pliegues: dos penalizados, Ridge y Lasso, ajustando alpha con GridSearchCV, y un modelo de arboles, Random Forest, ajustando numero de arboles, profundidad maxima y minimo de muestras por division. Evalúe todo sobre el conjunto de test, que nunca use para ajustar. Los resultados son contundentes: Random Forest gana con un RMSE de 537 dolares, un R2 de 0,98 y un MAPE de solo 6,35%, muy por encima de los modelos lineales, que se quedan en un R2 de 0,94. Comparando train y test, el R2 pasa de 0,993 a 0,982: una diferencia pequena, así que no hay sobreajuste preocupante. Exporte la tabla comparativa completa a un CSV en el repositorio."

Bloque 5 - Interpretacion y conclusiones (6:00 - 7:30)

En pantalla: En pantalla: barplot de importancia, top-10 errores y celda de conclusiones.

"La importancia de variables confirma el EDA: el tamaño físico y el quilataje concentran más del 90% de las decisiones del modelo, y la claridad hace el ajuste fino. Donde más falla el modelo es en los diamantes grandes y caros: los diez peores errores tienen un quilataje casi el doble del promedio, porque hay pocas observaciones de ese segmento para aprender. Como conclusión, Random Forest es un modelo sólido para tasación y detección de precios anómalos. Como trabajo futuro, propongo incorporar variables de mercado y probar Gradient Boosting con intervalos de predicción. Con esto termino mi presentación. Muchas gracias, profesor."

Checklist antes de subir el video

- Duración total menor o igual a 8:00 minutos.
- Se ve el notebook EJECUTADO (con sus salidas y graficos), no solo el código.
- Audio claro, sin ruido de fondo.
- Se cubren los 5 bloques del guion.
- Subir a YouTube (no listado), Google Drive, OneDrive o Loom con enlace público.
- Pegar el enlace en el README.md (sección 7) y hacer commit + push.